Web aplikacije, Predavanje 00

Uvod u kolegij i pravila polaganja

Fakultet informatike, Sveučilište Jurja Dobrile u Puli

izv. prof. dr. sc. Nikola Tanković

1 Čemu služi ovaj tekst

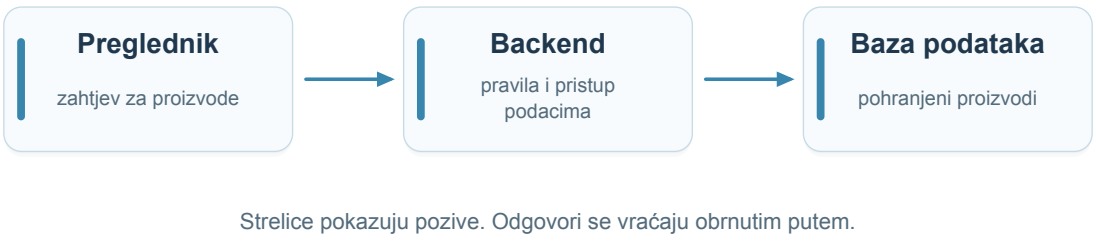
Ovo je pisani pratitelj uvodnog predavanja. Opisuje kako je kolegij organiziran, gdje pronaći materijale i pomoć, kako izgleda rad na projektu i kako se kolegij polaže. Tehnički sadržaj počinje u predavanju 01.

Pročitajte ga na početku semestra i vratite mu se prije predaje projekta. Ako se neko pravilo ovdje i na službenim mjestima kolegija razlikuje, vrijedi ono što nastavnik objavi na Moodleu i javnom webu kolegija.

2 Kolegij ukratko

2.1 Čime se kolegij bavi

Iz frontenda već znate kako aplikacija prikazuje podatke i kako ih dohvaća, na primjer preko Firebasea. Ovaj kolegij gleda drugu stranu: **što se događa kada zahtjev stigne na backend?** Preglednik poziva backend, a backend bazu podataka; odgovori se vraćaju obrnutim putem (Slika 1).



Slika 1: Put zahtjeva od preglednika preko backenda do baze. Odgovori se vraćaju obrnutim putem.

Kroz kolegij se stalno vraćamo istim pitanjima: gdje su pravila aplikacije i njezino stanje? Što ako dva zahtjeva stignu istodobno ili neka komponenta ne odgovori? Ako, na primjer, dva kupca istodobno naruče posljednji artikl, tko mora zaštititi zalihu? Primjer aplikacije za naručivanje služi učenju i nije zadana tema studentskog projekta.

2.2 Nastavnici i komunikacija

Dio nastave	Nastavnik
Predavanja	izv. prof. dr. sc. Nikola Tanković
Vježbe	Luka Blašković, mag. inf.

- **Pitanja o kolegiju:** Google Chat, grupa **„FIPU WA”**.
- **Moodle (e-učenje):** e-ucenje.unipu.hr
- **Javni web kolegija:** ntankovic.unipu.hr/wa

2.3 Plan nastave

Svako tehničko predavanje traje 90–120 minuta, uključujući raspravu i ponavljanje. Predavanja prate razvoj iste aplikacije za naručivanje.

Tjedan	Tema	Što radimo
01	Kako web aplikacije rade	Polazimo od poznatog frontenda i Firebasea. Pratimo kako preglednik traži podatke od poslužitelja i kako mu se vraća odgovor.
02	Arhitektura backend aplikacije	Razdvajamo kod koji prima zahtjev, provodi pravila aplikacije i pristupa podacima. Na primjeru narudžbe pokazujemo kako organizirati backend koji raste.
03	REST i dizajn API-ja	Dogovaramo kako frontend traži podatke i šalje promjene backendu. Oblikujemo adrese, poruke i odgovore na pogreške tako da ih klijent može jasno razumjeti.
04	Baze podataka i trajna pohrana	Spremamo proizvode i narudžbe tako da ostanu sačuvani nakon gašenja aplikacije. Upoznajemo osnove PostgreSQL-a i MongoDB-a te uspoređujemo izbor baze za projekt.
05	Transakcije i konkurentnost	Istražujemo što se događa kada dva kupca istodobno naruče posljednji artikl. Povezujemo promjene podataka u cjelinu i sprječavamo pogrešne zalihe.
06	Autentikacija i autorizacija	Razlikujemo prijavu korisnika od provjere što taj korisnik smije raditi. Štitimo narudžbe tako da korisnik ne može čitati ili mijenjati tuđe podatke.

Tjedan	Tema	Što radimo
07	Sigurnost web aplikacija	Provjeravamo što se događa kada netko namjerno pošalje neočekivane podatke. Učimo zaštititi unos, lozinke i tajne podatke te prepoznati česte propuste.
08	Asinkrona obrada u backendu	Izdvajamo sporije poslove, poput slanja e-pošte i izrade računa, iz obrade korisnikova zahtjeva. Pratimo kako se posao izvršava u pozadini i što ako ne uspije.
09	Pouzdanost i obrada pogrešaka	Razmatramo spor odgovor, nedostupnu uslugu i prekinutu vezu. Određujemo kada ponoviti pokušaj i kako spriječiti da ponavljanje dvaput izvrši istu narudžbu.
10	Performanse i skalabilnost	Mjerimo gdje aplikacija troši vrijeme prije nego što je ubrzavamo. Istražujemo brži pristup podacima, privremeno čuvanje rezultata i rad više primjeraka backenda.
11	Testiranje, praćenje i dijagnostika	Testovima provjeravamo očekivano ponašanje i pogreške. Pomoću zapisa rada i mjerenja rekonstruiramo što se dogodilo kada zahtjev zakaže ili postane spor.
12	Implementacija i rad u produkciji	Povezujemo dijelove aplikacije u sustav dostupan korisnicima. Razmatramo postavke, sigurno povezivanje, pokretanje i gašenje te nadogradnje aplikacije.

3 Predavanja i sudjelovanje

Dolazak na predavanja i vježbe nije obvezan. Ako dolazite, evidentirajte prisutnost QR kodom ili poveznicom bit.ly/wa-tu-sam i aktivno sudjelujte: postavljajte pitanja, predvidite rezultat i objasnite svoje odluke. Evidencija ne predstavlja bodovni prag.

AI dobro objašnjava pojmove, a materijali i, gdje postoje, snimke dostupni su i bez dolaska. Ako na predavanju samo slušate, oni vam mogu biti jednako dobri. Uživo dobivate nešto drugo:

- **odgovor na vlastito pitanje**, dok zabuna nastaje i na vašem primjeru;
- **prioritete**: što je bitno za projekt, obranu i usmeni, a što je samo zanimljivo;
- **razmišljanje naglas**: kako se rješava problem bez gotovog odgovora, s kompromisima i greškama;
- **raspravu s kolegama**: isti problem ima više obranjivih rješenja, a obrana traži upravo to.

Ako ste...	Predavanje vam daje...
samouki, s AI-jem i materijalima	provjeru razumijete li zaista; dođite barem kad zapnete

Ako ste...	Predavanje vam daje...
netko kome treba ritam	strukturu tjedna i manje gradiva za kraj semestra
tihi, ne volite pitati naglas	slušanje bez pritiska; pitanja možete postaviti u Google Chatu FIPU WA
zaposleni ili s obvezama	materijale i, gdje postoje, snimke za samostalan rad
usmjereni na ocjenu	način razmišljanja koji se traži na obrani i usmenom ispitu

Dođite kad vam to nešto daje. Ako dođete, sudjelujte.

4 Predznanje i tehnologije

4.1 Predznanje

Oslanjamo se na programiranje, JSON i iskustvo s frontend aplikacijama: **JavaScript**, **Vue**, **Pinia** i **Firebase**. Ako je dio toga zahrđao, obnovite ga na početku semestra.

HTTP učimo od početka. Ne pretpostavljamo znanje o HTTP-u, TCP-u ni mrežnoj komunikaciji iza poziva Firebase biblioteke. Kratka pojašnjenja dajemo kada su potrebna za backend problem.

4.2 Tehnologije u primjerima

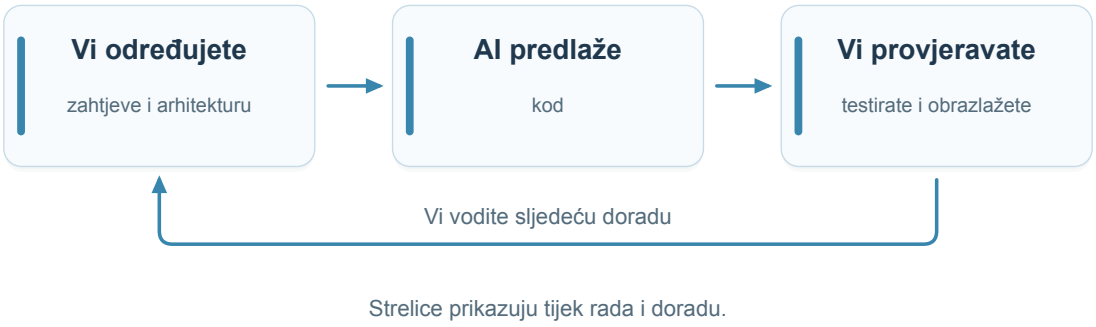
Dio aplikacije	Tehnologija
Frontend	Vue 3 i Pinia
API i backend	REST API i Node.js
Baza podataka	PostgreSQL ili MongoDB

Obradit ćemo osnove obiju baza, a za projekt birate jednu i obrazlažete izbor prema svojim podacima i načinu pristupa. Redis, redove poslova i Docker uvodimo samo kada pomažu objasniti konkretan mehanizam.

Za korištenje tehnologija u projektu koje se razlikuju od onih s predavanja i vježbi potrebno je **prethodno izričito odobrenje nastavnika**. To što se koncepti prenose na druge jezike i frameworkove ne znači da ih smijete samostalno odabrati za projekt.

5 AI i provjera razumijevanja

AI smijete koristiti, ali **vi provjeravate i objašnjavate rezultat**. Podjela uloga prikazana je na slici 2: vi određujete zahtjeve i arhitekturu, AI predlaže kod, a vi ga provjeravate, testirate i obrazlažete odluke.



Slika 2: Vi vodite rad, AI predlaže. Odgovornost za kod i odluke ostaje na vama.

Ako ste koristili AI, na obrani pokažite konkretnu provjeru koda, slučaj u kojem pretpostavke ne vrijede i moguću jednostavniju izvedbu. Cilj je samostalno obrazloženje i dokaz ponašanja, a ne količina generiranog koda.

Primjer. AI je u sučelju sakrio gumb za tuđu narudžbu. Je li time spriječen izravan zahtjev prema API-ju? Kako biste to provjerili?

Zapise razgovora s AI-jem ne predajete. Dovoljni su commitovi i obrana. Po želji u README-u projekta možete dodati kratak odjeljak „Uporaba AI-ja”: koje ste alate koristili, za što i kako ste provjerili rezultat.

Preporučeni alati. Za rad na kodu projekta, objašnjenja i provjere preporučuje se Claude Code; za ideje za sučelje i interaktivne prototipove Claude Design; za razumijevanje promjena i pregled koda Codex. Za istraživanje su dostupni i otvoreni modeli, na primjer Qwen3-Coder i DeepSeek-Coder-V2. Njihove su težine dostupne za preuzimanje, ali za pokretanje trebaju odgovarajući alat i računalo, a licence ovise o modelu. Izbor AI alata ne mijenja pravilo o odobrenju projektnih tehnologija. Alat predlaže — vi provjeravate i objašnjavate.

6 Projekt

6.1 Timski rad i individualni doprinos

Projekt izrađujete **u timu** i **kontinuirano**: **nekoliko commitova tjedno** kroz najmanje **2–3 tjedna**. Autentičnost commitova se provjerava, a prati se rad svakog člana. Projekt izrađen u nekoliko dana ili s jednim commitom ne zadovoljava traženi način rada.



Slika 3: Izmišljeni primjer povijesti commitova. Uz svaki commit vidljivi su autor i opis promjene.

Broj commitova sam po sebi ne pokazuje kvalitetu doprinosa; pregledava se sadržaj promjena. Timski rezultat ne zamjenjuje individualno razumijevanje: budite spremni objasniti vlastite promjene.

6.2 Nadogradnja ranije aplikacije

Možete zatražiti da projekt bude **nadogradnja aplikacije s prethodnog kolegija**, ako je ta aplikacija ocijenjena ocjenom **vrlo dobar (4) ili izvrstan (5)**. U zahtjevu nastavniku predstavite postojeću aplikaciju i predložite što biste nadogradili. To nije automatski prijenos stare ocjene; ostala pravila projekta i odobravanja tehnologija i dalje vrijede.

6.3 Ideje za projekt s AI funkcijom

Sljedeće ideje polazišta su za dogovor opsega, a ne gotove specifikacije. U njima AI koristi krajnji korisnik aplikacije, a ne samo programer pri pisanju koda.

Skupina	Ideja	AI funkcija	Što pamti backend
Osobni pomoćnici	01 · Ormar koji pamti	slaže odjevne kombinacije iz korisnikova ormara prema prilici i stilu	fotografije odjeće, favoriti, povijest kombinacija
	02 · Grad po mom tempu	predlaže šetnju prema interesima, vremenu i tempu; korisnik uređuje rutu	mjesta, spremljene rute, recenzije, plan obilaska
	03 · Trener za usmeni	postavlja potpitanja prema učitanim materijalima	materijali, pokušaji, povratne informacije, napredak

Skupina	Ideja	AI funkcija	Što pamti backend
	04 · Muzej osobnih predmeta	od fotografije i uspomene oblikuje priču za obiteljsku zbirku	predmeti, verzije priča, dopuštenja za dijeljenje
Svakodnevica i zajednica	05 · Hladnjak bez zaborava	predlaže obroke od postojećih namirnica i popis kupnje	zalihe, rokovi, plan obroka, zajednički popisi
	06 · Festival po mom ukusu	sastavlja osobni raspored i objašnjava preporuke	program, omiljeni događaji, spremljeni rasporedi
	07 · Klub čitatelja	povezuje interese članova, predlaže knjigu i pitanja za raspravu	knjige, grupe, glasovanja, susreti
	08 · Zeleni dnevnik	pomaže voditi dnevnik biljaka i predlaže što pratiti	biljke, fotografije, podsjetnici, opažanja
Podaci koji pričaju priču	09 · Detektiv kućnih troškova	razvrstava stavke računa i objašnjava promjene potrošnje	računi, kategorije, ispravci, mjesečni pregledi
	10 · Tim za dobru stvar	povezuje volontere s lokalnim akcijama	profili, akcije, prijave, odobravanja, obavijesti
	11 · Priče mog kvarta	od odobrenih priča stanovnika slaže tematske ture	lokacije, priče, izvori, uredničko odobravanje
	12 · Od ideje do hobija	pretvara ideju u male korake i prilagođava plan	projekti, zadaci, materijali, dnevnik napretka

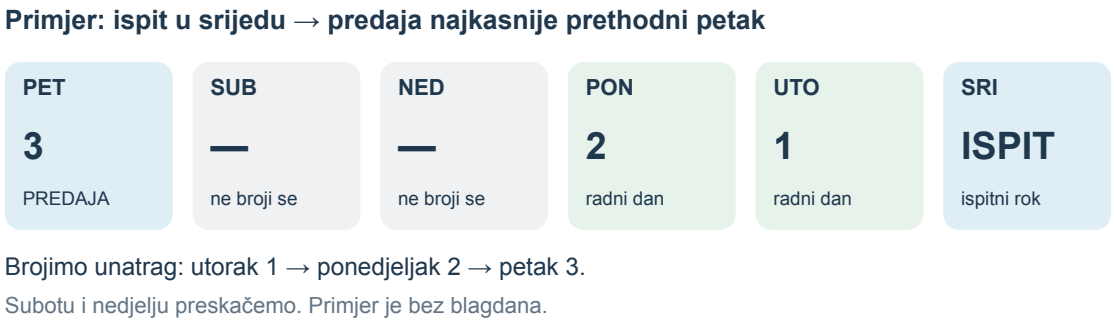
Za početak odaberite jednu glavnu AI funkciju i nekoliko povezanih korisničkih radnji. Projekt treba stvarnu pohranu, provjeru pristupa i smisleno ponašanje kada AI odgovor kasni ili ne uspije. Poziv modela i tajni ključ ostaju na backendu. Korisnik može pregledati, ispraviti i potvrditi AI prijedlog. Ideje ne uvode nove obvezne tehnologije ni plaćenu pretplatu; odstupanja od nastavnih tehnologija i dalje traže odobrenje nastavnika.

7 Kako položiti kolegij

7.1 Predaja projekta: brojite radne dane

Gotov projekt uvjet je za pristup ispitu. Projekt predajete najmanje **3 radna dana prije ispitnog roka**. Slijede **obrana projekta i usmeni ispit**.

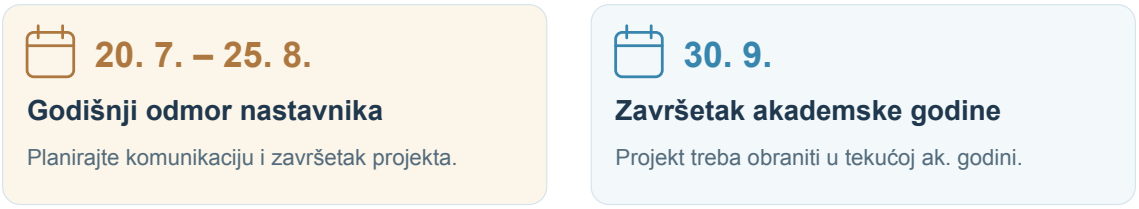
Tri radna dana nisu tri kalendarska dana. Za ispit u srijedu predaja je najkasnije prethodni petak: utorak je prvi, ponedjeljak drugi, a petak treći radni dan unatrag, dok se subota i nedjelja ne broje (Slika 4). Blagdani se također ne broje kao radni dani. Planirajte završetak i provjeru projekta prije krajnjeg roka.



Slika 4: Primjer brojanja radnih dana unatrag od ispita, bez blagdana.

7.2 Ako projekt ne obranite ove godine

Akademska godina završava **30. rujna**. Godišnji odmor nastavnika traje od 20. srpnja do 25. kolovoza (Slika 5). Taj datum nije zajamčeni ispitni termin, a godišnji odmor nije službena promjena rasporeda ispitnih rokova.



Slika 5: Kraj akademske godine i godišnji odmor nastavnika.

Neuspješan pojedinačni izlazak na ispit ne znači odmah novu temu. Ali ako projekt ne obranite do završetka akademske godine:

- ponovno prijavljujete projekt,
- izrađujete **novi projekt samostalno** i branite ga.

Prijedlog novog projekta odobrava nastavnik.

7.3 Znanje za usmeni ispit

Za usmeni ispit postoji dokument „Pitanja za usmeni ispit – Web aplikacije”. **Popis pitanja je vodilja, a ne iscrpan popis** ni zbirka odgovora za učenje napamet. Pokriva ove

cjeline:

- mreža, HTTP/HTTPS, CORS i REST;
- Express.js, middleware i autentikacija;
- Vue 3, komponente, usmjeravanje i stanje;
- Axios, osnove PostgreSQL-a i MongoDB-a te operacije nad podacima;
- praktična primjena i sve što koristite u projektu.

Opseg uključuje **službenu literaturu, predavanja i vježbe**. Obuhvaća i JavaScript te poznati frontend, pa obnovite predznanje i povežite ga s backendom. Cjeline uključuju usporedbe pristupa i praktična pitanja, primjerice REST, SOAP i GraphQL, obradu grešaka i implementaciju funkcionalnosti.

8 Kako se pripremiti za obranu

8.1 Pokažite razumijevanje projekta

Na obrani ne pokazujete samo da projekt radi, nego i da razumijete zašto radi. Slika 6 prikazuje tri koraka: predvidite očekivani rezultat, pokažite kod i stvarni zahtjev, a zatim objasnite opaženi rezultat.



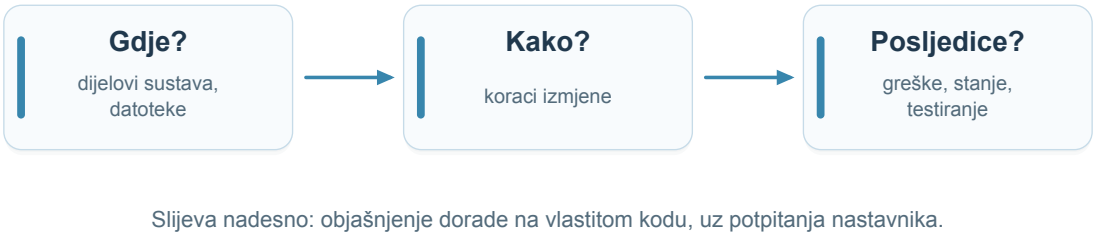
Slika 6: Tri koraka objašnjenja projekta.

Pratite jednu funkcionalnost kroz cijelu aplikaciju: **klik → HTTP zahtjev → backend → baza → prikaz**. Pokažite karticu **Network** u alatima preglednika, relevantan kod te uspješan ili neuspješan slučaj. Povežite URL, metodu, zaglavlja, tijelo, status i odgovor s konkretnim kodom. Za dijagnostiku povežite karticu Network, konzolu i backend logove.

Budite spremni objasniti arhitekturu, organizaciju komponenti, konfiguraciju i postavljanje aplikacije. Na testnim podacima možete pokazati neispravan izravan API zahtjev, pristup tuđem zapisu, spor backend ili dvostruki klik na Spremi; odaberite primjer koji vaš projekt doista podržava. Pitanja se biraju prema funkcionalnostima vašeg projekta.

8.2 Dorada projekta: objasnite izmjenu

Umjesto izmjene koda uživo objašnjavate doradu na vlastitom projektu (Slika 7): gdje bi izmjena išla (Vue komponenta, ruta, middleware, baza), kako biste je proveli i koje su posljedice za greške, stanje i testiranje. Nastavnik zatim postavlja potpitanja. Manju izmjenu po potrebi možete pokazati u kodu, bez AI alata, lokalno na testnim podacima.



Slika 7: Tri koraka objašnjenja izmjene na vlastitom projektu.

Primjeri pitanja (pitanja se biraju prema projektu, pa ih ne dobiva svaki student):

- Kako biste dodali **obvezno polje** od obrasca do baze? Što se događa sa starim zapisima bez tog polja?
- Gdje biste provjerili da korisnik mijenja **samo svoje zapise**?
- Što se događa ako se isti zahtjev za spremanje **pošalje dvaput**?
- Što ako backend ne odgovori i kako biste provjerili da izmjena radi?

9 Kontrolni popis

Prije prvog tehničkog predavanja trebali biste znati:

- ☐ gdje se nalaze materijali i pravila kolegija (Moodle, javni web kolegija);
- ☐ gdje postaviti pitanje (Google Chat, „FIPU WA”);
- ☐ koje tehnologije koristimo i da za druge trebate prethodno odobrenje nastavnika;
- ☐ da je AI dopušten, ali da odgovarate za kod i odluke te ih morate znati provjeriti;
- ☐ da projekt radite u timu i kontinuirano, s nekoliko commitova tjedno kroz najmanje 2–3 tjedna;
- ☐ da projekt predajete najmanje 3 radna dana prije ispitnog roka, a slijede obrana i usmeni ispit;
- ☐ što se događa ako projekt ne obranite do 30. rujna.

Sljedeće predavanje polazi od nečega što već znate: kliknemo „Prikaži proizvode” i čekamo da se podaci pojave. **Odakle dolaze podaci? Što se događa između klika i prikaza?**